

Chatbot 设备端接入文档

Chatbot 设备端接入文档

文档变更记录

日期	版本	操作内容	操作人
25.09.30	V1.0	接口定义	邹益强

1. 接入流程

1.1 申请接入

设备接入纳管平台后，调用 chatbot 接口需要申请 token 并注明设备端或者 sdk 接入 chatbot 接口，邮件发送至：

- 主要联系人：zouyiqiang_fx@cmdc.chinamobile.com;
zhucaiwen_fx@cmdc.chinamobile.com
- 抄送：zhengzhongwei_fx@cmdc.chinamobile.com

测试环境信息：

- 测试 token：sk-hZT1DsE14MTjBKrs40D330D85b3f452882D4B2F7919eE32b
- 模型上下文长度：8K

2. Chatbot 接口

2.1 接口描述

此接口提供九天大模型服务，支持多种 AI 能力：

能力类别	描述	示例	使用模型
闲聊	支持日常对话、心	• 日常对话：我今	九天大模型

	心理咨询、情感咨询等场景	天很开心哈哈 • 心理咨询：我好焦虑，我该怎么办 • 情感咨询：我失恋啦，好难受呀？	
天气查询	查询现在、过去、未来的天气情况，包含天气、温度、空气质量等	• 今天天气怎么样 • 明天有雨吗？ • 昨天北京气温怎么样？	
限行查询	查询指定城市限行号、过去、当前、未来等限行信息	• 北京今天限行几号？ • 北京未来一周的限行号？	-
时间查询	查询当前时间、以后时间、国外时间、时差等信息	• 现在几点钟了？ • 东京现在几点？ • 北京和东京的时差	-
百科查询	城市、历史、地理、人物、景点、诗词、食物、汽车等百科内容	• 帮我介绍一下北京这个城市 • 介绍一下孙中山 • 介绍一下小满节气	-
彩票查询	彩票玩法规则、开奖时间、中奖号码等信息	• 介绍一下大乐透的玩法规则 • 大乐透的开奖时间是什么时候？ • 25059 期大乐透的中奖号码是多少？	-

股票查询	股市大盘、特定股票查询等信息	• 今天的股市怎么样? • 英伟达股价是多少?	-
汇率查询	各种货币汇率查询	• 美元和人民币的汇率是多少?	-
计算	初等数学计算, 包含四则运算、比较大小、复杂运算	• $4 \times 5 + 2$ 等于多少? • 2 的 2 次方和 3 的 6 次方谁更大? • $1/40$ 比 1.5 的最简整数比是多少?	-
应用题	应用场景的数学计算	• 15 个同学踢毽子平均分为三组每组几人?	-
单位换算	长度、重量、面积、体积、温度、速度、时间、货币等单位换算	• 1 英寸等于多少厘米? • 1 升等于多少毫升?	-
翻译	词语、句子的指定语言翻译	• 很高兴见到你用英语怎么说 • factory 什么意思呀	-
汉语	汉字、词语、成语、典故、诗词等汉语知识查询	• 一个黑一个今念什么 • 掩耳盗铃是什么意思 • 来一首陆游的诗	-
新闻	热点、时事、政	• 今日有什么热点	-

	治、经济、体育、娱乐等类型资讯	新闻？ • 2025 年国际体育赛事 • 《哪吒 2》好看吗	
笑话	讲笑话娱乐功能	• 你讲个笑话 • 给我讲一个东北话版本的笑话吧	-
人设画像	心理辅导、知心伙伴等人设聊天；孙悟空、超级飞侠等 IP 人设聊天	• 用孙悟空的角色和我聊天吧	-
兜底处理	针对上述场景之外未覆盖到的场景，进行兜底的 AIGC 对话	-	九天大模型

2.2 请求接口

请求 URL：

Plain Text

POST https://ivs.chinamobiledevice.com:11443/device-api/ai/v2/chat/completions

2.3 请求参数

2.3.1 请求头参数

参数名	类型	必填	描述
sign	String	是	<code>`\${deviceSecret}`</code>

			<code>\${timestamp}</code> 进行 md5 加密 例： deviceSecret 为 xxx, ts 为 1740017297000 则 sign 为 <code>md5(xxx1740017297000) = 97e71a943871dbb932f11316f54b36d3</code>
deviceNo	String	是	设备号，产品内唯一标识设备的字符串
productId	String	是	产品 ID
productKey	String	是	产品密钥
ts	String	是	请求时的毫秒时间戳，请保证每次请求时时间戳不一样
deviceId	String	是	设备纳管获取到的设备 id
authorization	String	是	大模型调用 token

2.3.2 请求 Body 参数

参数名	类型	必填	示例	描述
messages	array	是	<code>[{"role": "user", "content": "Hello!"}]</code>	对话消息列表，包含 system,assistant,user 角色和内容，多轮对话需要附带

				上下文内容
model	string	是	"jiutian-lan"	使用的模型
stream	boolean	否	true	是否启用流式响应
temperature	number	否	0.1	控制输出随机性，范围 0-1
top_p	number	否	0.1	控制输出多样性，范围 0-1

2.4 请求示例

```
JSON
{
  "model": "jiutian-lan",
  "messages": [
    {
      "role": "system",
      "content": "You are a helpful assistant."
    },
    {
      "role": "user",
      "content": "Who won the world series in 2020?"
    },
    {
      "role": "assistant",
      "content": "The Dodgers won the World Series in 2020."
    },
    {
      "role": "user",
      "content": "Where was it played?"
    }
  ],
  "temperature": 0.1,
  "top_p": 0.1,
  "stream": false
}
```

2.5 响应示例

2.5.1 成功响应（非流式）

```
JSON
{
  "id": "chatcmpl-abc123",
  "object": "chat.completion",
  "created": 1677651234,
  "model": "jiutian_75b",
  "choices": [
    {
      "index": 0,
      "message": {
        "role": "assistant",
        "content": "The 2020 World Series was played at Globe Life Field in Arlington, Texas."
      },
      "finish_reason": "stop"
    }
  ],
  "usage": {
    "prompt_tokens": 56,
    "completion_tokens": 15,
    "total_tokens": 71
  }
}
```

2.5.2 成功响应（流式）

```
Plain Text
data: {"created":1725503116,"model":"jiutian-lan","id":"547c93d6-0ed7-4ce0-bf41-4f618c874192","choices":[{"delta":{"role":"assistant","index":0,"type":"text","content":"2","status":"init"}}],"object":"chat.completion.chunk"}

data: {"created":1725503116,"model":"jiutian-lan","id":"547c93d6-0ed7-4ce0-bf41-4f618c874192","choices":[{"delta":{"role":"assistant","index":0,"type":"text","content":"*","status":"init"}}],"object":"chat.completion.chunk"}
```

```
data: {"created":1725503117,"model":"jiutian-lan","id":"547c93d6-0ed7-4ce0-bf41-4f618c874192","choices":[{"delta":{"role":"assistant","index":0,"type":"text","content":"3","status":"init"}}],"object":"chat.completion.chunk"}
```

```
data: {"created":1725503117,"model":"jiutian-lan","id":"547c93d6-0ed7-4ce0-bf41-4f618c874192","choices":[{"delta":{"role":"assistant","index":0,"type":"text","content":"=", "status":"init"}}],"object":"chat.completion.chunk"}
```

```
data: {"created":1725503117,"model":"jiutian-lan","id":"547c93d6-0ed7-4ce0-bf41-4f618c874192","choices":[{"delta":{"role":"assistant","index":0,"type":"text","content":"6","status":"init"}}],"object":"chat.completion.chunk"}
```

```
data: {"created":1725503117,"usage":{"completion_tokens":7,"prompt_tokens":15,"total_tokens":22},"model":"jiutian-lan","id":"547c93d6-0ed7-4ce0-bf41-4f618c874192","choices":[{"delta":{"role":"assistant","finish_reason":"stop","index":0,"type":"text","status":"finish"}}],"completionMsg":{"modelId":"jiutian-lan","modelVersion":"V3"},"object":"chat.completion.chunk"}
```

2.5.3 失败响应

```
JSON
{
  "error": {
    "message": "认证失败",
    "type": "invalid_request_error",
    "param": null,
    "code": "unauthorized"
  }
}
```

2.5.4 内容风控响应

```
JSON
{
```



```
{
  "id": "chatcmpl-xyz456",
  "object": "chat.completion",
  "created": 1677651234,
  "model": "jiutian_75b",
  "choices": [
    {
      "index": 0,
      "message": {
        "role": "assistant",
        "content": "抱歉，我无法提供该内容。"
      },
      "finish_reason": "content_filter"
    }
  ]
}
```

3. 常见问题

3.1 模型上下文长度限制

Q: 模型上下文长度是多少，超过了怎么处理？

A: 目前服务端模型最大支持 8K 上下文长度。模型上下文内容由客户端发送，为避免异常情况，客户端请求大模型接口时，如果上下文长度超过 8K 需要做截断处理。

3.2 系统提示词配置

建议系统提示词：

Plain Text

你是中国移动的智能助理灵犀。如果我问你是谁，你需要回答："您好，我是中国移动智能助理灵犀"；如果我问你是什么模型，你需要回答："我是由中国移动研究院人工智能团队开发的九天大模型"。

4. 注意事项

1. **时间戳要求：**每次请求的时间戳必须不同，建议使用当前毫秒时间戳
2. **签名算法：** $\text{sign} = \text{md5}(\text{deviceSecret} + \text{timestamp})$
3. **上下文管理：**客户端需要自行管理对话上下文，超过 8K 需要截断
4. **错误处理：**建议对各种错误响应做好处理，包括认证失败、内容风控等情况

5. **流式响应：**流式响应适用于需要实时显示生成内容的场景