

中国移动灵犀AI泛终端管理平台大模型端云对接文档

文档变更记录

日期	版本	操作内容	操作人
25.09.30	V1.0	接口定义	邹益强
26.01.06	v1.0.4	增加图片识别大模型	邹益强
26.03.11	v1.0.5	更新平台名称	邱云枫

1. 接入流程

1.1 申请接入

设备接入算力平台后，调用端云接口需要申请token并注明设备端或者sdk接入chatbot接口，备注厂商信息，需要调用的模型名称，邮件发送至410778394@qq.com抄送：

- zouyiqiang_fx@cmdc.chinamobile.com；zhucaiwen_fx@cmdc.chinamobile.com；zhengzhongwei_fx@cmdc.chinamobile.com；qiuyunfeng_fx@cmdc.chinamobile.com

2. 端云接口

2.1 接口描述

此接口提供九天大模型服务，支持多种AI能力：

- 模型上下文长度：8K

能力类别	描述	示例	使用模型
闲聊	支持日常对话、心理咨询、情感咨询等场景	· 日常对话：我今天很开心哈哈 · 心理咨询：我好焦虑，我该怎么办 · 情感咨询：我失恋啦，好难受呀？	九天大模型

天气查询	查询现在、过去、未来的天气情况，包含天气、温度、空气质量等	· 今天天气怎么样 · 明天有雨吗？ · 昨天北京气温怎么样？	
限行查询	查询指定城市限行号、过去、当前、未来等限行信息	· 北京今天限行几号？ · 北京未来一周的限行号？	-
时间查询	查询当前时间、以后时间、国外时间、时差等信息	· 现在几点钟了？ · 东京现在几点？ · 北京和东京的时差	-
百科查询	城市、历史、地理、人物、景点、诗词、食物、汽车等百科内容	· 帮我介绍一下北京这个城市 · 介绍一下孙中山 · 介绍一下小满节气	-
彩票查询	彩票玩法规则、开奖时间、中奖号码等信息	· 介绍一下大乐透的玩法规则 · 大乐透的开奖时间是什么时候？ · 25059期大乐透的中奖号码是多少？	-
股票查询	股市大盘、特定股票查询等信息	· 今天的股市怎么样？ · 英伟达股价是多少？	-
汇率查询	各种货币汇率查询	· 美元和人民币的汇率是多少？	-
计算	初等数学计算，包含四则运算、比较大小、复杂运算	· $4 \times 5 + 2$ 等于多少？ · 2的2次方和3的6次方谁更大？ · 1/40比1.5的最简整数比是多少？	-
应用题	应用场景的数学计算	· 15个同学踢毽子平均分为三组每组几人？	-
单位换算	长度、重量、面积、体积、温度、速度、时间、货币等单位换算	· 1英寸等于多少厘米？ · 1升等于多少毫升？	-
翻译	词语、句子的指定语言翻译	· 很高兴见到你用英语怎么说 · factory什么意思呀	-

汉语	汉字、词语、成语、典故、诗词等汉语知识查询	· 一个黑一个今念什么 · 掩耳盗铃是什么意思 · 来一首陆游的诗	-
新闻	热点、时事、政治、经济、体育、娱乐等类型资讯	· 今日有什么热点新闻？ · 2025年国际体育赛事 · 《哪吒2》好看吗	-
笑话	讲笑话娱乐功能	· 你讲个笑话 · 给我讲一个东北话版本的笑话吧	-
人设画像	心理辅导、知心伙伴等人设聊天；孙悟空、超级飞侠等IP人设聊天	· 用孙悟空的角色和我聊天吧	-
兜底处理	针对上述场景之外未覆盖到的场景，进行兜底的AIGC对话	-	九天大模型

2.2 请求接口

请求URL：

代码块

1 POST https://ivs.chinamobiledevice.com:11443/device-api/ai/v2/chat/completions

2.3 请求参数

2.3.1 请求头参数

参数名	类型	必填	描述
sign	String	是	<code>\${deviceSecret}\${timestamp}</code> 进行md5加密 例：deviceSecret为xxx，ts为1740017297000 则sign为md5(xxx1740017297000) = 97e71a943871dbb932f11316f54b36d3
deviceNo	String	是	设备号，产品内唯一标识设备的字符串

productId	String	是	产品ID
productKey	String	是	产品密钥
ts	String	是	请求时的毫秒时间戳，请保证每次请求时时间戳不一样
deviceId	String	是	设备纳管获取到的设备id
ip	String	是	设备ip
authorization	String	是	Bearer {大模型调用token}

2.3.2 请求Body参数

参数名	类型	必填	示例	描述
messages	array	是	要生成句子的提示和上下文，如： <pre>[{"role":"system","content":"You are a helpful assistant."}, {"role":"user","content":"Who won the world series in 2020?"}, {"role":"assistant","content":"The Dodgers won the World Series in 2020."}, {"role":"user","content":"Where was it played?"}]</pre> 图片识别： <pre>[{"role":"user","content": [{"type":"text","text":"描述这张图片"}, {"type":"image_url","image_url": {"url":"data:image/jpeg;base64,""\$BASE64_IMAGE"\$\$\$}}]</pre>	对话消息列表，包含 system、assistant、user角色和内容，多轮对话需要附带上下文内容
model	string	是	"jiutian-lan" "jiutian-image" "jiutian-chat"	jiutian-lan：文本大模型 jiutian-image：图片识别大模型 jiutian-chat:非生成式模型（用于儿童手表）
stream	boolean	否	true	是否启用流式响应
temperature	number	否	0.7	控制输出随机性，范围0-1

top_p	number	否	0.9	控制输出多样性，范围0-1
-------	--------	---	-----	---------------

2.4 请求示例

代码块

```
1
2  {
3    "model": "jiutian-lan",
4    "messages": [
5      {
6        "role": "system",
7        "content": "You are a helpful assistant."
8      },
9      {
10       "role": "user",
11       "content": "Who won the world series in 2020?"
12     },
13     {
14       "role": "assistant",
15       "content": "The Dodgers won the World Series in 2020."
16     },
17     {
18       "role": "user",
19       "content": "Where was it played?"
20     }
21   ],
22   "temperature": 0.1,
23   "top_p": 0.1,
24   "stream": true
25 }
26
27
```

2.5 响应示例

2.5.1 成功响应（非流式）

代码块

```
1  {
2    "id": "chatcmpl-abc123",
3    "object": "chat.completion",
4    "created": 1677651234,
5    "model": "jiutian_75b",
```

```

6     "choices": [
7         {
8             "index": 0,
9             "message": {
10                "role": "assistant",
11                "content": "The 2020 World Series was played at Globe Life Field in
Arlington, Texas."
12            },
13            "finish_reason": "stop"
14        }
15    ],
16    "usage": {
17        "prompt_tokens": 56,
18        "completion_tokens": 15,
19        "total_tokens": 71
20    }
21 }

```

2.5.2 成功响应（流式）

代码块

```

1  data: {"created":1725503116,"model":"jiutian-lan","id":"547c93d6-0ed7-4ce0-
bf41-4f618c874192","choices":[{"delta":
{"role":"assistant","index":0,"type":"text","content":"2","status":"init"}}],"o
bject":"chat.completion.chunk"}
2
3  data: {"created":1725503116,"model":"jiutian-lan","id":"547c93d6-0ed7-4ce0-
bf41-4f618c874192","choices":[{"delta":
{"role":"assistant","index":0,"type":"text","content":"*", "status":"init"}}],"o
bject":"chat.completion.chunk"}
4
5  data: {"created":1725503117,"model":"jiutian-lan","id":"547c93d6-0ed7-4ce0-
bf41-4f618c874192","choices":[{"delta":
{"role":"assistant","index":0,"type":"text","content":"3","status":"init"}}],"o
bject":"chat.completion.chunk"}
6
7  data: {"created":1725503117,"model":"jiutian-lan","id":"547c93d6-0ed7-4ce0-
bf41-4f618c874192","choices":[{"delta":
{"role":"assistant","index":0,"type":"text","content":"=", "status":"init"}}],"o
bject":"chat.completion.chunk"}
8
9  data: {"created":1725503117,"model":"jiutian-lan","id":"547c93d6-0ed7-4ce0-
bf41-4f618c874192","choices":[{"delta":
{"role":"assistant","index":0,"type":"text","content":"6","status":"init"}}],"o
bject":"chat.completion.chunk"}

```

```
10
11 data: {"created":1725503117,"usage":
{"completion_tokens":7,"prompt_tokens":15,"total_tokens":22},"model":"jiutian-
lan","id":"547c93d6-0ed7-4ce0-bf41-4f618c874192","choices":[{"delta":
{"role":"assistant","finish_reason":"stop","index":0,"type":"text","status":"fi
nish"}}],"completionMsg":{"modelId":"jiutian-
lan","modelVersion":"V3"},"object":"chat.completion.chunk"}
```

2.5.3 失败响应

代码块

```
1  {
2    "error": {
3      "message": "认证失败",
4      "type": "invalid_request_error",
5      "param": null,
6      "code": "unauthorized"
7    }
8  }
```

2.5.4 内容风控响应

代码块

```
1  {
2    "id": "chatcmpl-xyz456",
3    "object": "chat.completion",
4    "created": 1677651234,
5    "model": "jiutian_75b",
6    "choices": [
7      {
8        "index": 0,
9        "message": {
10         "role": "assistant",
11         "content": "抱歉，我无法提供该内容。"
12       },
13       "finish_reason": "content_filter"
14     }
15   ]
16 }
```

3. 常见问题

3.1 模型上下文长度限制

Q：模型上下文长度是多少，超过了怎么处理？

A：目前服务端模型最大支持8K上下文长度。模型上下文内容由客户端发送，为避免异常情况，客户端请求大模型接口时，如果上下文长度超过8K需要做截断处理。

3.2 系统提示词配置

建议系统提示词：

代码块

- 1 你是中国移动的智能助理灵犀。如果我问你是谁，你需要回答："您好，我是中国移动智能助理灵犀"；如果我问你是什么模型，你需要回答："我是由中国移动研究院人工智能团队开发的九天大模型"。

4. 注意事项

1. **时间戳要求：**每次请求的时间戳必须不同，建议使用当前毫秒时间戳
2. **签名算法：** $\text{sign} = \text{md5}(\text{deviceSecret} + \text{timestamp})$
3. **上下文管理：**客户端需要自行管理对话上下文，超过8K需要截断
4. **错误处理：**建议对各种错误响应做好处理，包括认证失败、内容风控等情况
5. **流式响应：**流式响应适用于需要实时显示生成内容的场景